融合大语言模型与轻量模型协同优化的兴趣点轨迹预测框架

魏蕴田[1]，金苍宏[1,2]，费峥东[1]，郑铜亚[1,2]，王晓亮[3]

（1.浙大城市学院 计算机与计算科学学院，浙江 杭州 310000；2.浙大城市学院 超大规模图数据高性能智能计算研究中心，浙江 杭州 310000；3.中国移动通信集团浙江有限公司，浙江 杭州 310000）

摘　要：针对兴趣点(point of interest，POI)预测任务中由于轨迹稀疏性与行为复杂性导致的时空信息表征难与影响因素融合难的挑战。本研究提出大语言模型(Large Language Model，LLM)与轻量模型协同优化的兴趣点轨迹预测框架(LLM Reflective Fusion Architecture，LLM-RFA)，对影响兴趣点轨迹行为的内外部因素进行融合表达。模型首先采用端到端轨迹预测方法生成候选 POI 集合，减少大模型输入 Token；其次，将历史轨迹混入噪声数据，通过时序图结构表征，设计历史轨迹点重排任务，引导 LLM 进行首轮预测；再次，预训练轻量级纠正小模型，从访问点类别偏好、轨迹语义一致性等角度引导 LLM 反思，通过大小模型协同，最终提升预测精确度。模型在 NYC、TKY、CA 等 3 个公开数集上的实验表明，协同优化后模型预测精度均有所提升，且基于 DeepSeek-R1 基座的 TOP1 准确率上超越现有基线方法 0.3-11%，同时，消融实验显示内外因素与各个组件对预测结果的不同影响。

关键词：行为时空表征；兴趣点轨迹预测；大语言模型；纠错机制；大小模型协同

中图分类号：TP 391　　**文献标志码：**A　　**文章编号：**

A Collaborative Optimization Framework Combining Large Language Models and Lightweight Models for Point Of Interest Trajectory Prediction

WEI YunTian[1], JIN CangHong[1,2], FEI ZhengDong[1], ZHENG TongYa[1,2], WANG XiaoLiang[3]

（1. *School of Computer and Computer Science*, *Hangzhou City University*, *Hangzhou* 310000, *China*；2. *Very Large Scale Intelligent Graph Computing Research Center*, *Zhejiang University*, *Hangzhou* 310000, *China*；3. *China Mobile Communications Group Zhejiang Co., Ltd*, *Hangzhou* 310000, *China*）

Abstract: Point of Interest (POI) prediction faces two core challenges: poor spatiotemporal information representation and difficult integration of influencing factors, due to trajectory sparsity and complex user mobility. To address these, this study proposes the LLM Reflective Fusion Architecture (LLM-RFA), a POI trajectory prediction framework enabling collaborative optimization between Large Language Models (LLMs) and lightweight models, aiming to integrate internal and external factors shaping POI trajectory behaviors.LLM-RFA adopts three key steps: first, an end-to-end method generates candidate POI sets to reduce LLM input tokens; second, noise is incorporated into historical trajectories, which are represented via temporal graphs, and a trajectory point rearrangement task guides the LLM’s initial prediction; third, a pre-trained lightweight correction model prompts the LLM’s reflection on user preferences for POI categories and trajectory semantic consistency, with LLM-lightweight model synergy enhancing mobility pattern capture. Experiments on three public datasets (NYC, TKY, CA) show consistent accuracy i

收稿日期：2025-07-31.　　**网址：**

基金项目：新一代人工智能科技重大专项 (2022Z0119100);浙江省自然科学基金委员会 (LZ25F020012)；浙江省自然科学基金委员会项目 (LZHS24F020001).

作者简介：魏蕴田(2000-), 男, 浙江金华, 硕士生, 从事兴趣点轨迹预测研究. orcid.org/0009-0009-1857-150X. E-mail: 2230101024@stu.hzcu.edu.cn

通信联系人：金苍宏, 男, 副教授, 博士. E-mail: jinch@hzcu.edu.cn

mprovements for LLM-RFA. Specifically, its TOP1 accuracy (based on the DeepSeek-R1 backbone) outperforms existing baselines by 0.3–11%. Ablation experiments further verify distinct impacts of internal/external factors and each component on predictions, validating the framework's rationality. In conclusion, LLM-RFA effectively resolves POI prediction's core challenges, strengthens spatiotemporal characterization and factor integration, and offers a robust solution to advance POI prediction performance.
Key words: behavioral spatiotemporal representation; point of interest trajectory prediction; large language model; error correction mechanism; collaboration between large and small model

随着信息通信和数据采集技术的快速发展，如全球定位系统(Global Positioning System，GPS)[1]位置社交网络服务(Location-Based Social Networks，LBSNs)[2]等，存储了大量的包含时空间信息的轨迹数据，对用户行为提供关键理解洞察，应用于提升城市规划能力、预测犯罪趋势等场景[3]。

在兴趣点(Point Of Interest，POI)预测任务中，根据历史轨迹预测未来行为，可将 POI 预测转换成时间序列预测问题[4]，依靠循环神经网络和注意力机制来挖掘用户的访问模式[5]，捕捉其旅行轨迹和行为动机。如 Xie 等[6]提出 STAR-HiT 模型，该模型通过分层 Transformer 架构，对签到序列中的多粒度时空上下文进行递归建模。Xu 等[7]利用堆叠多层 Transformer 以显式建模轨迹中非连续访问之间的时空关系。但是单纯时间序列模型在处理交互信息以及全局 POI 关联时存在局限性，且编码器堆叠加深易出现梯度爆炸等问题，因此后续研究逐渐基于图神经网络(graph neural network，GNN)开展算法研究。GNN 通过构建全局 POI 转换图和用户相似度图，以图卷积等方式提升用户和 POI 的表示能力[8]，将终点交互信息融入时空图中，使模型能够同时捕捉访问路径和 POI 间的交互关系[9][10]，但模型对计算和存储的需求较高。为了解决资源问题，提出将 GNN 或 GCN 与注意力机制相结合[11]。如 Luo 等[12]对连续兴趣点和非连续兴趣点采用双重注意力机制。Liu 等[13]通过自注意力机制专注于最相似和最重要的用户以捕获更多个性化的偏好，Lim 等[14]融合空间、时间和用户偏好信息，引入图注意力机制。

近年来，随着大语言模型(Large Language Model，LLM)在自然语言语义理解能力的显著提高，新的研究尝试将 LLM 集成至 POI 预测系统[15]，Tang 等[16]提出了大语言模型与时序图处理表征方法，通过微调(Fine Turning)时空数据，将 POI 预测任务转换为问答任务。但 LLM 上下文受限难以精准建模长期或周期性的用户移动规律，且微调过程伴随着显著的计算成本和内存开销，在资源受限环境中效率低。同时，轨迹数据往往稀疏易导致过拟合，难以充分利用样本信息。

近期，DeepSeek-R1 等推理模型多场景应用，证明了通过激发大语言模型自身的反思能力来提高任务预测精度是一条可行的路线[17]。因此，本研究提出了一种融合大语言模型与轻量模型协同优化的兴趣点轨迹预测框架(LLM Reflective Fusion Architecture，LLM-RFA)。框架通过三阶段协同推理机制实现高效精准的兴趣点轨迹预测：首先，利用传统 POI 轨迹预测方法生成候选 POI 集合，充分保留时空行为的多模态特征；其次，构建时序图并设计历史轨迹点重排任务让大语言模型(LLM)提前学习时序知识，再将候选集与上下文信息转化为自然语言描述，输入大语言模型(LLM)进行第一次语义推理与决策；最后，设计轻量级纠正模型，通过分析 LLM 决策逻辑中的潜在错误(如类别偏好偏差、时序连贯性不足)生成反馈建议，驱动 LLM 迭代预测并优化预测结果。

1 方法设计

不同阶段的端到端的预测方法(如表 1 所示)对时空数据的编码能力在持续增强。FPMC[18]，DeepMove[19]等早期方法多围绕历史轨迹与时间信息等基础维度展开，LSTPM[20]，STAN[12]等方法逐步纳入空间信息以强化位置依赖建模，

GETNext[21]，STHGCN[22]等方法进一步引入位置属性与社交关系，LLM4POI[15]则将群体影响维度转化为自然语言融入大语言模型，本研究则对影响个体行为所有因素进行有效表示。

表 1　POI 预测方法的数据维度覆盖性对比表

Tab. 1　Comparison of data dimensions of POI prediction methods

Methods	历史轨迹	时间信息	空间信息	位置属性	群体影响
FPMC	☑	☑	☒	☒	☒
DeepMove	☑	☑	☒	☒	☒
LSTPM	☑	☑	☑	☒	☒
STAN	☑	☑	☑	☒	☒
Graph-Flashback	☑	☑	☑	☑	☒
GETNext	☑	☑	☑	☑	☒
STHGCN	☑	☑	☑	☑	☒
ROTAN	☑	☑	☑	☑	☒
LLM4POI	☑	☑	☑	☑	☑
LLM - RFA(Ours)	☑	☑	☑	☑	☑

为了有效捕捉用户移动模式中的潜在行为意图，建立三阶段协同推理机制实现高效精准的 POI 轨迹预测，各个阶段依赖于 POI 的含义，用户历史轨迹，时间信息以及群体对个体的影响。整体框架如图 1 所示：

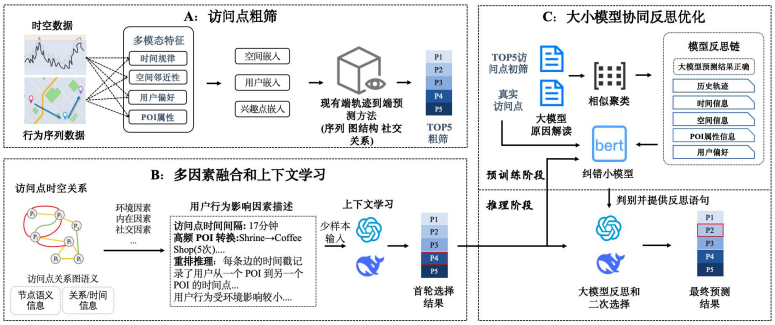


图 1　LLM-RFA 框架图

Fig. 1 LLM-RFA Framework

1.1 访问点粗筛

为了生成高质量的候选 POI 集合，本研究受到 ROTAN(A Rotation-based Temporal Attention Network)[23]的启发，通过旋转操作将 POI 嵌入映射到时间敏感的向量空间，动态捕捉用户行为中的时间特异性模式。其核心思想是通过旋转操作(Rotation Operation)和时序注意力机制(Temporal Attention)捕捉用户行为中的时间特异性模式，从而提升预测精度。旋转是通过单位复数建模的，给定一个嵌入向量$\boldsymbol{f} \in \mathbb{C}^d$，其时间信息旋转(TR)操作数学定义如下：

$$TR(\boldsymbol{f}, r_t) = \boldsymbol{f} \circ r_t, where\,|\,r_t\,| = 1. \tag{1}$$

式中：$r_t \in \mathbb{C}^d$ 表示与时间段t相关的旋转；“$\circ$”表示哈达玛乘积。

ROTAN 通过旋转操作将时间信息直接嵌入 POI 语义空间，避免了传统方法中时间特征与空间特征的拼接问题，显著提升了特征融合效率，为大语言模型决策发挥优势奠定了基础。实验结果表明，ROTAN 生成的粗筛点在覆盖率和多样性上优于传统方法，后续实验中将与其他基线方法进行对比，选取初筛效果最好的方法进行实验。

1.2 多因素融合和上下文学习

为使大语言模型可以更好的理解轨迹任务，本研究在大语言模型推理之前先构建时序图让其学习对应用户的时序模式，将用户轨迹视为图 G

(Node, Edge, Timestamp)，其中节点 Node 是 POI (兴趣点)，属性包含 POI id、POI 类别、地理位置(经纬度)；边 Edge 是用户在不同时间点的移动轨迹，属性包含时间戳、停留时长；时序维度 Timestamp 是通过时间戳构建边的顺序，形成序列。接着打乱用户的历史访问兴趣点的顺序并将轨迹图进行编码，将图的特征与任务以提示词(Prompt)的形式输入大语言模型，让其分析该用户的时序模式。如图 2 所示，其中{shuffled_pois}表示被打乱的用户历史轨迹，{traj_graph_str}表示结构图输入的信息，{POI_id}表示兴趣点 ID，{POI_category}表示兴趣点含义，{latitude},{longitude}表示兴趣点的经纬度坐标，{u}→{v}表示两个点之间有边，{last_checkin_epoch_time}表示访问兴趣点的时间戳，{time_interval}表示两点之间时间间隔，{graph.nodes}表示图的节点数量，{graph_embeddings}表示图的维度信息。

	Content
Prompt	<Shuffled_pois>Given that the user has visited the following POIs in their historical trajectory (with the order shuffled): {shuffled_pois}. <Trajectory rearrangement>Please rearrange these POIs based on the time - series graph information and analyze the basis for ordering (such as time intervals, spatial distances). <Trajectory Graph Input>Detailed information of the trajectory graph: {traj_graph_str}
Trajectory Graph Input	Nodes (Time, Location, POI Info): {poi_id},{poi_category}, coordinates: ({latitude}, {longitude}) Edges: {u}→{v}, Timestamp: {last_checkin_epoch_time} Interval: {time_interval} seconds Number of Nodes: {graph.nodes} Feature Dimension: {graph_embedding_dims}

图 2 图结构输入模式与时序模式学习提示词

Fig. 2 Graph Structure Input Mode and Time-Series Pattern Learning Prompt Words

有研究指出将行人作为生态系统中的一部分能显著提升预测的实时性和准确性[24]；另有方法提出了一种群体运动模式模型，该模型利用场来刻画个体在不同位置的方向性运动和流动[25]。基于上述研究，结合 POI 预测任务数据集的轨迹特征，本研究将运动行为影响因素划分为内部状态与外部因素：个体历史行为定义为内部状态，群体运动模式与区域关系归类为外部因素。

本研究受到 CLIP(Contrastive Language-Image Pre-training)[26]启发，将用户签到数据与时空数据等多元异构信息转换为自然语言问答形式，以此构建提示词的基础框架。先将原始数据中的关键要素例如时间、用户标识、兴趣点 ID、类别及最高访问时段转化为“用户在 XX 时间访问 XX 类别兴趣点”的场景化描述。在此基础上，融合前期通过轨迹重排任务学习到的时序知识，形成基础信息与规律总结的双层输入结构，为模型提供推理依据。同时采用长 CoT(Chain-of-Thought)[27]的小样本提示作为示例，在提示词中嵌入先分析用户历史访问规律，再结合当前场景匹配粗筛 POI 的推理步骤，引导模型通过多步验证生成轨迹问答的首次预测结果。提示词(Prompt)与输入格式如图 3 所示，其中{utc_time}表示时间，{user_id}表示用户 ID，{poi_id}表示兴趣点 ID，{poi_category}表示兴趣点的含义，{max_prob_time_slot}表示兴趣点最容易被访问的时间段，{patterns_str}表示上一步得到的时序知识。

	Content
Prompt	You are a professional trajectory point prediction assistant. I will provide POI points along with their corresponding descriptions. Given a user's trajectory path points and five candidate POIs (where the order of these five candidates has no bearing on the probability of the correct answer), please select the POI that the user is most likely to visit next. Output only the poi_id in the following format: -poiid:1234.
Question Input	<Internal factors>At {utc_time}, user {user_id} visited POI {poi_id} (category: {poi_category}, with the highest visit probability during {max_prob_time_slot}). <External factors>Among the three most frequently visited POIs in user {user_id}'s history, one is {poi_id}, which also has the highest visit probability during {max_prob_time_slot}.... <Time-series pattern>Learned time-series pattern knowledge: {patterns_str}

图 3 大语言模型提示与用户签到数据结构

Fig. 3 Large language model prompts and user sign in data structure

1.3 大小模型协同反思优化

为了提升大语言模型(LLM)在轨迹预测任务中的鲁棒性与泛化能力，本研究设计了一种轻量级纠正模型协同优化框架。如图 1C 所示，先基于文本聚类方法构建轻量级纠正模型的训练数据，随后利用纠正模型的输出作为反馈信号驱动大语言模型进行动态推理修正，从而在无需微调的前提下提升预测准确性。轻量级纠正模型提升大模型性能的核心在于通过知识传递、监督引导与数据筛选等方式，弥补大模型在任务适配、训练效率或推理能力上的短板。本研究设计轻量级纠正模型释放监督信号来引导大语言模型实现预测准确率超越纯微调模型。其反思机制分为三阶段形成语言反馈闭环：

1. 语言化反思生成阶段：大语言模型基于首次预测生成可解释的反思文本，明确错误原因与调整规则并通过聚类算法生成几类模板。

2. 反馈解析阶段：轻量级纠正模型输出判断转化为上述结构化语言。

3. 反馈决策衔接阶段：结构化语言作为大语言模型二次预测的引导提示，替代通用提示，确保调整规则被精确执行。

聚类算法通过三阶段优化实现高维稀疏文本空间向低维紧致语义空间的映射。首先，采用改进的 TF-IDF 加权词袋模型与深度语义嵌入的联合表示：设文档集合为 $D=\{d_1,d_2,...,d_N\}$，对于文档 d_i，其向量 $\boldsymbol{v}_i$ 表示为：

$$\boldsymbol{v}_i=\alpha\cdot T(TF-IDF(d_i))+(1-\alpha)\cdot BERT_{CLE}(d_i). \quad (2)$$

式中：$\alpha\in[0,1]$ 为自适应权重参数，通过熵值最大化准则动态调节统计特征与深度语义的贡献度；$T(TF-IDF(d_i))$ 表示对 TF - IDF 向量做维度变换，使得前后向量维度保持一致；$BERT_{CLE}(d_i)$ 表示文档 d_i 的 $BERT$ 语义表示，通过提取 $BERT$ 模型输出的[CLS]标记隐藏状态向量得到，捕捉文档的深度语义信息。其次构建语义相似矩阵 $\boldsymbol{S}\in\mathbb{R}^{N\times N}$：

$$s_{ij}=\exp(-\frac{\|\boldsymbol{v}_i-\boldsymbol{v}_j\|^2}{2\sigma^2})\cdot\cos(\theta_{BERT}(\boldsymbol{d}_i,\boldsymbol{d}_j)). \quad (3)$$

式中：σ 表示高斯核函数的带宽参数，控制相似度衰减的速度；$\cos(\theta_{BERT}(\boldsymbol{d}_i,\boldsymbol{d}_j))$ 表示文档之间语义表示的余弦相似度，用于增强语义一致性。并且引入了带图正则化的非负矩阵分解(GNMF)进行潜在语义挖掘：

$$\min_{W,H\geq 0}\|\boldsymbol{X}-\boldsymbol{W}H\|_F^2+\lambda Tr(H^TLH)+\mu\|H\|_1. \quad (4)$$

式中：$\boldsymbol{X}$ 表示输入矩阵，每一列代表一个文档的向量表示；$\boldsymbol{W}$ 潜在语义空间中的基向量；H 表示文档在潜在语义空间中的低维表示；$\|\boldsymbol{X}-\boldsymbol{W}H\|_F^2$ 表示重构误差的 Frobenius 范数，衡量分解后的矩阵与原始矩阵的差异；λ 表示图正则化项的权重参数，控制流形结构的保留程度，$Tr(H^TLH)$ 表示图正则化项；$\boldsymbol{L}=\boldsymbol{D}-\boldsymbol{S}$ 是图拉普拉斯矩阵，$\boldsymbol{D}$ 为度矩阵，$\boldsymbol{S}$ 是相似度矩阵；μ 表示稀疏正则化项的权重参数，控制系数矩阵的稀疏性。最后选取前 $\boldsymbol{k}$ 个特征向量构成正交空间进行最终划分：

$$C^*=\arg\min_{\{C_1,...,C_k\}}\sum_{i=1}^{k}\sum_{x\in C_i}\|x-\mu_i\|_{DTW}. \quad (5)$$

式中：C^* 表示最优的聚类划分；x 表示文档在低维空间中的表示；μ_i 表示第 i 个聚类簇的中心；DWT 表示采用动态时间规整距离度量解决文本序列长度不一致的问题。

1.3.1 轻量级纠正模型　本研究设计了一个基于监督学习的轻量级纠正小模型用于判别大语言模型(LLM)预测结果的合理性。输入数据包括大语言模型的输入(粗筛 POI、用户历史轨迹等文本描述)以及大语言模型预测结果，输入通过 BERT 的分词器(Tokenizer)将其编码为输入向量。输入格式为：

Input=Tokenize(Question,Top5,Predict)。Question 表示大语言模型的 Question 输入，Top5 为粗筛 POI 列表，Predict 为大语言模型的预测结果。然后将编码之后的输入向量输入 BERT 模型，提取文本特征：

$$h = BERT(Input). \tag{6}$$

式中: h 表示 BERT 输出的池化特征。BERT 输出的基础上，通过一个全连接层(Linear Layer)和 Dropout 层进行分类：

$$y = Soft\max(W \cdot Dropout(h) + b). \tag{7}$$

式中，W 和 b 是可学习参数；y 是分类概率分布；其分类标签规则如下：

$$y = \begin{cases} 1, \varnothing & y_{LLM} = y_{true} \\ 0, y_{err} & y_{LLM} \neq y_{true} \end{cases} \tag{8}$$

式中：y_{LLM}表示其大语言模型预测的真实值；y_{true}表示真实值；y_{err}表示用于大模型纠正的提示词，其来源于上述文本聚类方法的输出。若轻量级纠正模型判定大语言模型预测正确，则以大语言模型输出作为最终结果；反之，基于轻量级纠正模型的标签引导大语言模型重新推理，实现纠错目的。

损失函数采用交叉熵损失函数进行训练：

$$L = -\sum_{i=1}^{N} y_i \log(\hat{y_i}). \tag{9}$$

式中：y_i 是真实标签，$\hat{y_i}$ 是模型预测概率分布。

LLM-RFA 框架整体伪代码如下所示：

输入：数据集 *D (NYC/TKY/CA)*；*End_to_end_model*(传统端到端模型)；-*Corrector_model* (BERT 轻量级纠正模型)；*LLM*(大语言基座模型：Deepseek-R1/Qwen/GPT-4)

输出：用户下一个将要去的 POI 点 *Finall_POI*

1：计算特征：*prob_time_slot(poi)* (poi 时段访问概率)、*group_pattern* (群体高频 poi)

2：访问点粗筛

3：*Emb = Embedding(poi.emb, poi.timestamp)*

4：*POI_candidates = End_to_end_model(Emb,u.history_trajectory，5)*

5：LLM 首次预测

6：构建用户轨迹图 *G = (Node,Edge,Timestamp)*

7：*shuffled_pois = Shuffle(u.history_trajectory.poi_sequence)* -打乱用户历史 POI 序列

8：*Traj_graph_str = Encode(G)* -编码图结构

9：*temporal_knowledge=LLM.Generate(prompt$_{pattern}$)* -引导学习时序知识

10：编码内外因素：*internal_factors*（个体历史行为）、*external_factors*（群体/区域特征）

11：*LLM_pred$_{initial}$ = LLM.Generate(prompt$_{pred}$)* -首次预测

12：大小模型协同优化

13：*prompt$_{reflect}$ = Text_clustering(error_reason).* -语言化反思生成

14: *Correction_result = Corrector_model(prompt$_{pred,}$ POI_candidates, LLM_pred$_{initial}$)*

15：*if Correction_result == true*

16： *then Final_POP = LLM_pred$_{initial}$*

17：*else prompt$_{reflect}$ = Corrector_model_Feedback (Correction_result).* -反馈解析

18：*LLM_pred = LLM.Generate(prompt$_{reflect,}$)* -反馈决策

19: *Finall_POI = LLM_pred*

2 性能评估

2.1 实验准备

本研究在 Foursquare-NYC[28]、Foursquare-TKY[28]和 Gowalla-CA[29]3 个真实数据集上进行对比实验，实验在配备 4 张 NVIDIA GeForce RTX 4090 显卡的硬件环境下，完成 3 个数据集统计信息如表 2 所示，时间分布如图 4 所示。NYC 数据集的 POI 分布主要聚集在纽约曼哈顿核心商业区与布鲁克林部分街区，呈现高度密集的网格化结构；TKY 数据集则以东京涩谷、新宿、银座等若干节点化热点为主，各节点周围半径范围内集中了多种业态；CA 数据集覆盖范围更广，旧金山湾

区、洛杉矶市区与圣地亚哥等地的 POI 密度各自形成独立簇。最后，三地的地点类型均呈长尾分布，其中餐饮、购物和景点为主要类别。

表 2　三个真实数据集统计数据

Tab. 2　Statistics of three real data sets

数据集	NYC	TKY	CA
Users	1047	2281	3951
POIs	4937	7821	9670
Check-ins	80166	306345	168922
Records	8347	29610	15597

注：Users 为用户数，POIs 兴趣点的数量，Check-ins 为用户签到次数，Records 代表记录数。

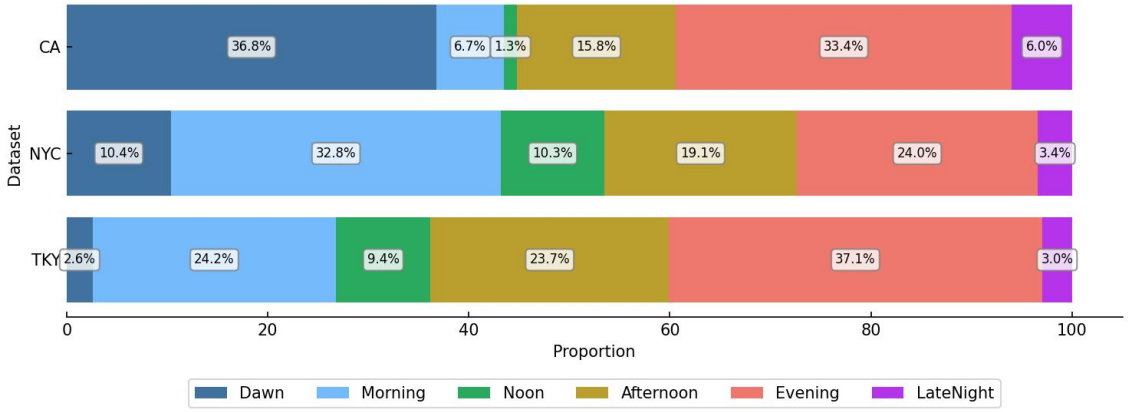


图 4 数据集兴趣点时间占比分布图

Fig. 4 Time distribution of interest points in datasets

2.1.1 数据预处理　数据集包含签到记录，这些记录包括用户 id、POI_id、纬度、经度和时间戳，每个用户的签到记录按照时间戳的顺序排列成为每日序列。从数据中进行数据统计，统计每个 POI 点被访问的时间段的概率以及用户历史访问 POI 点的规律，随后将粗筛结果与特征信息转化为自然语言描述构建大语言模型决策与轻量级纠正模型的数据集。

2.1.2 评估指标　本研究采用基于排名的评价指标，Accuracy@1 (Acc@1)。设测试集中有 N 个样本，每个样本包含用户的历史轨迹和实际访问的 POI l_{true}。对于每个样本，模型预测的 POI 为 l_{pred}。Acc@1 的计算公式为：

$$Acc@1 = \frac{1}{N}\sum_{i=1}^{N}(l_{pred}^{(i)} = l_{true}^{(i)}). \tag{10}$$

在 POI 预测任务中，Acc@1 越高，说明模型能够更准确地预测用户的下一个访问地点。

MRR(Mean Reciprocal Rank)是排序任务中常用的评价指标，用于衡量模型对正确结果的排序能力，其计算计算公式为：

$$MRR = \frac{1}{Q}\sum_{i=1}^{Q}\frac{1}{rank_i}. \tag{11}$$

式中：Q 为查询总数；$rank_i$ 为第 i 个查询的正确答案在排序结果中的位置。

本研究在访问点初筛模块中已隐含 ACC@5 代表真实的未来位置出现在模型给出的最有可能的五个预测结果中的概率的评估指标，访问点初筛模块中 ACC@5 的值相较于 ACC@1 的值有非常大的提升，如表 6 所示，表明初筛模型已经具备良好的排序基础。且通过多因素融合和上下文学习模块提到时序图重排任务引导 LLM 学习用户个性化轨迹模式已隐含对个性化模式的捕捉，并通过 LLM 上下文学习植入动态因素以提升准确率。

2.2 基线方法

本研究采用了 10 个已被广泛使用的基线模型进行实验：

FPMC[18]：它结合了矩阵分解和一阶马尔可夫链来捕捉用户的总体偏好和他们的序列行为。

DeepMove[19]：这种方法结合了一个门控循环单元和注意力机制，以有效地识别用户签到行为中的周期性和序列模式。

LSTPM[20]：一个先进的模型，结合了长期和短期的序列方法来进行预测。

STAN[12]：这个双层注意力架构利用签到的时空信息来捕捉 POI 之间的相互依赖关系。

Flashback[30]：这种基于 RNN 的方法利用时空上下文进行回顾性位置预测，从而利用丰富的时空信息。

Graph-Flashback[31]：该模型将获取的 POI 转换图集成到基于 RNN 的框架中，以增强对序列转换模式的理解。

GETNext[21]：该框架基于 Transformer 架构，并利用用户轨迹图以及 POI 转换概率图来改进下一个 POI 预测。

STHGCN[22]：使用超图捕获用户内部和用户之间的轨迹，并将超图结构编码与时空信息相结合。

ROTAN[23]：通过旋转操作将 POI 嵌入映射到时间敏感的向量空间，并结合时序注意力机制动态捕捉用户行为中的时间特异性模式，从而提升下一 POI 预测的准确性。

LLM4POI[15]：通过将用户历史轨迹、时间信息和 POI 语义转化为自然语言描述，利用大语言模型(LLM)的语义理解能力直接预测下一个 POI，从而避免了传统方法中复杂的特征工程和时空依赖建模。LLM4POI 采用的是大语言模型的微调方法，训练参数量大，时间成本高，需要较大的硬件支持，无法按照原论文的参数复现结果，因此遵循了原论文中的实验数据。

在本研究的方法中，将采用三种不同的大语言模型作为实验基座，分别是 Qwen-turbo、GPT-4 和 DeepSeek-R1，并且记录了大语言模型直接预测的结果与纠错之后的结果，进行对比来展示纠错模块的效果。在纠错小模型的训练中，将批量大小设置为 16，轮数设置为 50，为了进一步增强方法，本研究使用了 Adam 优化器初始学习率为 $2*10^{-5}$，基础结构包含 12 层 Transformer 编码器，隐藏层维度为 768。模型整体架构采用预训练模型加分类头的设计。首先通过 BERT 模型提取文本特征，使用其 pooler_output 作为句子级表示，接着通过一个 dropout 层(dropout 率为 0.1)进行正则化处理，最后通过一个全连接层将 768 维的特征映射到与标签类别数相等的输出维度，实现分类任务。对于所有基线模型，遵循其原始论文中指定的默认超参数配置，并确保每种方法都经历了相同数量的训练周期。

2.3 实验结果

表 3 展示了 TKY、NYC 和 CA 的数据集上基线方法和本研究方法的性能，最佳性能以粗体文本强调，而次佳结果则用下划线表示。为达到最佳预测结果，本研究将使用 ACC@5 最高的初筛模型(Rotan 与 STHGCN)生成初筛兴趣点进行实验。图 5 展示了不同模型在 Acc@1 及 MRR 性能对比。大语言模型的输出形式与传统预测模型不同，在设计上更聚焦利用语义理解与推理能力输出精准结果，因此其不具备生成 5 个结果的条件。从实验数据中可以发现，DeepSeek-R1 实验结果普遍优于传统基线方法与其他模型方法，可能是由于 Deepseek-R1 与其他模型相比增加了思考推理部分。但是该框架在 NYC 数据集上与最先进的基线方法(LLM4POI)相比略有差距，但优于其他传统和基于深度学习的基线模型。经过分析发现，LLM4POI 通过数据集特定微调，能针对性优化热门地点的预测权重，而本研究方法缺乏针对此类分布的自适应调整，对非热门 POI 的预测会存在偏差，因此，本研究对 LLM-RFA(DeepSeek-R1)上新增头/长尾 POI 细分指标，取前 20%标注为头部 POI，后 50%标注为长尾 POI，实验结果如表 4 所示。从实验数据中可以看出，在 NYC 数据集上，头部 POI 的预测效果要远优于尾部 POI 的预测效果，因此微调方法针对性优化热门地点的优势将被放大。尽管 LLM-RFA(DeepSeek-R1)因缺乏热门 POI 自适应优化机制，但可以在整体的预测中保持稳定的预测精度，在 TKY 与 CA 数据集上可以实现

性能的反超充分体现了 LLM-RFA 框架对不同密度 POI 分布场景的泛化适配性。

表 3　三个真实数据集上的位置预测结果

Tab. 3　Location prediction results on three real data sets

方法	TKY			NYC			CA		
	Acc@1	Acc@5	MRR	Acc@1	Acc@5	MRR	Acc@1	Acc@5	MRR
FPMC	0.1668	0.3852	0.2696	0.1231	0.1512	0.1136	0.0383	0.0702	0.0911
DeepMove	0.2386	0.4184	0.3660	0.1255	0.1580	0.1324	0.0625	0.1304	0.0982
LSTPM	0.2150	0.4650	0.3309	0.1188	0.1671	0.1301	0.0773	0.2015	0.1461
STAN	0.1963	0.3798	0.2852	0.1296	0.1991	0.1328	0.0891	0.2096	0.1869
Flashback	0.2058	0.4932	0.3530	0.1356	0.1939	0.1430	0.0946	0.2195	0.1963
Graph-Flashback	0.2222	0.4969	0.3541	0.1434	0.2312	0.1541	0.1319	0.2979	0.2169
GETNext	0.2154	0.4994	0.3453	0.1371	0.2294	0.1553	0.1301	0.2852	0.2103
STHGCN	0.2950	0.5187	0.3913	0.1905	0.2478	0.1653	0.1530	0.3329	0.2158
ROTAN	0.2308	0.4567	0.3358	0.3094	0.5255	0.4071	0.1965	0.3286	0.2608
LLM4POI	0.3035	-	-	**0.3372**	-	-	0.2065	-	-
LLM-RFA(Deepseek-R1)	**0.3166**	0.5187	0.4562	0.3259	0.5255	0.6239	**0.3285**	0.3329	0.5138
LLM-RFA(Qwen)	0.3050	0.5187	0.4316	0.2835	0.5255	0.5293	0.2900	0.3329	0.4550
LLM-RFA(Gpt-4o)	0.2800	0.5187	0.3245	0.3162	0.5255	0.4281	0.3125	0.3329	0.4448
LLM-RFA(Gpt-4)	0.2381	0.5187	0.3125	0.2222	0.5255	0.3931	0.2692	0.3329	0.3733

注：Acc@5 代表真实的未来位置出现在模型给出的最有可能的五个预测结果中的概率。LLM4POI 原文中未提供 Acc@5 指标，因此表格中未展示。

表 4　头/长尾 POI 细分指标实验数据

Tab .4　Head/long tail POI subdivision index experimental data

方法	TKY		NYC		CA	
	Acc@1-Head	Acc@1-Tail	Acc@1-Head	Acc@1-Tail	Acc@1-Head	Acc@1-Tail
LLM-RFA(Deepseek-R1)	0.4931	0.2524	0.5349	0.2275	0.4207	0.2716

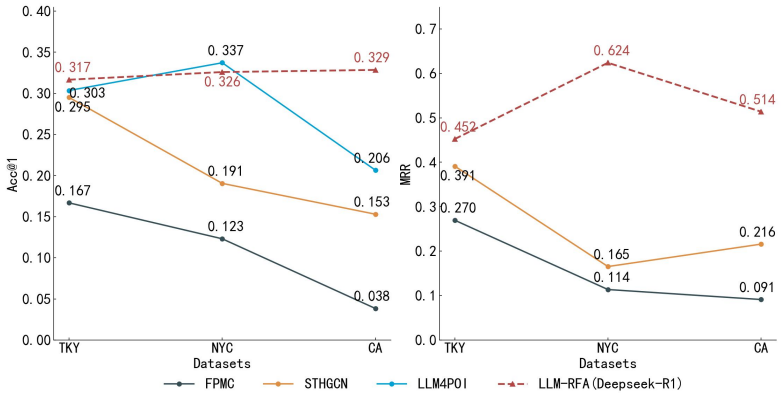


图 5　Acc@1 和 MRR 模型性能对比图

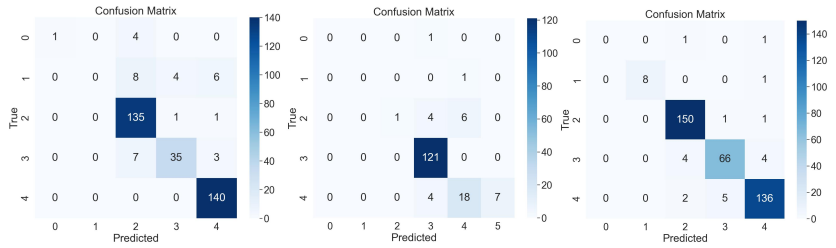
Fig. 5 Comparison of Model Performance between Acc@1 and MRR

轻量级纠正模型的实验数据在表 5 中展示，同时列出了轻量级模型应用 GPT-4 训练时的混淆矩阵，如图 6 所示。Gpt-4 系列模型在细粒度语义解析、时空关联捕捉上表现突出，能精准理解轨迹文本中隐含的时空逻辑因此轻量级模型基于二者的性能较好[16]，Deepseek-R1 侧重逻辑链连贯性，在时序逻辑清晰的场景适配性佳，但对数据分布相关的文本细节捕捉不足，部分数据集上性能稍弱，Qwen 在时空轨迹领域的文本适配性存在短板，难以精准解析轨迹文本中结构化与非结构化信息的关联，导致轻量级模型获取的错误判断依据精度不足，整体性能最低[32]。从轻量级模型的整体准确率可以看出，轻量级纠正模型有能力为大语言模型提供正确的纠错的建议。

表 5　轻量级模型训练准确率

Tab. 5　Accuracy of lightweight model training

	Qwen	Gpt-4o	Gpt-4	Deepseek-R1
TKY	0.8363	0.9571	0.9014	0.9235
NYC	0.8886	0.9047	0.8719	0.8585
CA	0.8658	0.9501	0.9474	0.9188



(a)TKY(GPT-4)混淆矩阵　(b)NYC(GPT-4)混淆矩阵　(c)CA(GPT-4)混淆矩阵

图 6　轻量级模型训练混淆矩阵

Fig. 6　Confusion Matrix of Lightweight Model Training

为了验证整体框架的实验效率，本研究在 LLM4POI 与 LLM-RFA(DeepSeek-R1)两个方法上统计了训练时间以及推理延迟，并计算了框架中粗筛模块(Rotan)的训练时长，如表 6 所示。从实验数据中可以发现，虽然二者的推理延迟比较接近，但是 LLM-RFA 的训练效率远高于大模型微调方法。在所需资源方面，LLM4POI 在原文中提到需要若干 A100 显卡，而本研究配备 4 张 NVIDIA GeForce RTX 4090 显卡无法按照原文参数复现结果，但是在 LLM-RFA 框架上已能取得较好的效果。

表 6　训练消耗时长统计表(s(秒)/epoch)

Tab. 6　Statistical Table of Training Duration

方法	推理延迟	训练时长
LLM4POI	1.3467	5760
Rotan	5.2500	37.09
LLM-RFA	0.7409	5.2137

为验证轻量级纠正模型的作用，本研究列出了各种大模型基座下使用轻量级纠正模型纠错前后的实验数据对比，如表 7 所示。从实验数据可以看出，轻量级纠正模型可以提升约 4-5%预测准确率，能有效的提高大语言模型预测的准确率，同时其训练参数量小，无需较大的硬件支持，时间成本远低于大语言模型的微调。

表 7　纠错前后实验数据对比

Tab. 7　Comparison of Experimental Data Before and After Error Correction

方法	TKY		NYC		CA	
	纠正前 Acc@1	纠正后 Acc@1	纠正前 Acc@1	纠正后 Acc@1	纠正前 Acc@1	纠正后 Acc@1
LLM-RFA(Deepseek-R1)	0.2743	0.3166	0.2848	0.3259	0.2727	0.3285
LLM-RFA(Qwen)	0.2523	0.3050	0.2474	0.2835	0.2609	0.2900
LLM-RFA(Gpt-4o)	0.2379	0.2800	0.2776	0.3162	0.2174	0.3125
LLM-RFA(Gpt-4)	0.2167	0.2381	0.1836	0.2222	0.2173	0.2692

为验证 LLM-RFA 模型整体框架的整体性能，同时验证用户的社交关系以及群体对个体影响信息对其预测性能的影响，本研究分别在 Deepseek-R1 上设计了 LLM-RFAS 和 LLM-RFAG 两组消融模型开展实验。LLM-RFAS 不考虑用户的偏好，目的是验证内部因素对模型性能的影响；LLM-RFAG，不考虑群体对个体的影响，目的是验证外部因素对模型性能的影响。同样使用 Acc@1 作为预测性能的评价指标，对 LLM-RFA 与两组消融模型在三个数据集上的预测效果进行对比，实验结果如表 8 所示。图 7 可以直观的看出 LLM-RFA 在 3 个数据集上的 Acc@1 始终大于其他两种消融模型，证明用户的个人偏好以及群体对个体影响信息对于 POI 预测的最终效果都是至关重要的，两

种偏好信息的融合有助于提升个性化 POI 预测的效果。

表 8　内外因消融实验结果

Tab. 8　Results of Ablation Experiment on Internal and External Factors

方法	TKY		NYC		CA	
	Acc@1	MRR	Acc@1	MRR	Acc@1	MRR
LLM-RFA(Deepseek-R1)	0.3166	0.4562	0.3259	0.6239	0.3285	0.5138
LLM-RFAS	0.2855	0.3998	0.2778	0.5751	0.2692	0.3587
LLM-RFAG	0.2830	0.4003	0.2857	0.6172	0.2115	0.3360

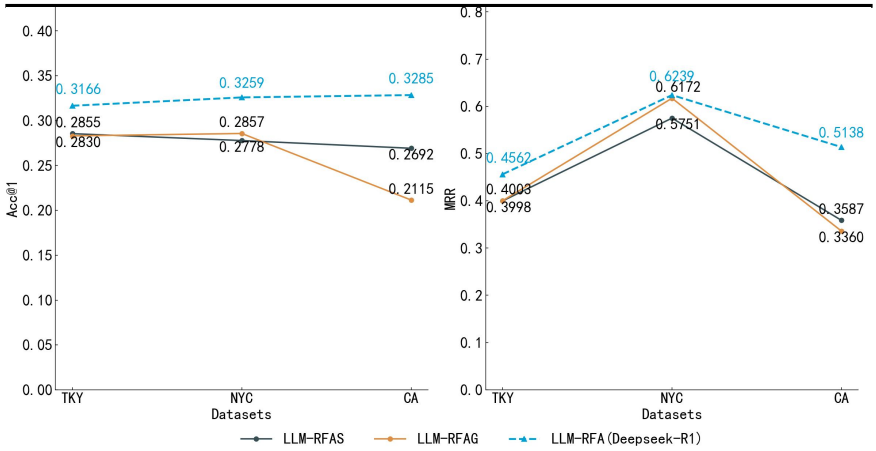


图 7 内外因素消融实验结果图

Fig. 7 Results of Ablation Experiment on Internal and External Factors

为了进一步探索框架中各组件对结果的影响，本研究设计了两组消融实验，LLM-RFA(Deepseek-R1)-S 代表替换粗筛方法为基线方法中的 GETNext，LLM-RFA(Deepseek-R1)-N 表示删除了其中的多因素融合和上下文学习部分中的用户轨迹重排任务，实验数据如表 9 所示。从实验数据中可以看出，LLM-RFA(Deepseek-R1)框架在 TKY、NYC、CA 数据集的 Acc@1 和 MRR 指标上，均优于替换粗筛方法的 LLM-RFA(Deepseek-R1)-S 与删除影响因素解构及用户轨迹重排的 LLM-RFA(Deepseek-R1)-N，这表明框架中的访问点粗筛方法、影响因素解构、用户轨迹重排等组件，对提升 POI 预测精度具有重要作用。

表 9　各组件消融实验结果

Tab. 9　Ablation test results of each component

方法	TKY		NYC		CA	
	Acc@1	MRR	Acc@1	MRR	Acc@1	MRR
LLM-RFA(Deepseek-R1)	0.3166	0.4562	0.3259	0.6239	0.3285	0.5138
LLM-RFA(Deepseek-R1)-S	0.2982	0.3230	0.3098	0.4673	0.2982	0.3158
LLM-RFA(Deepseek-R1)-N	0.2957	0.3197	0.2784	0.4563	0.3076	0.3650

3　结 语

本研究聚焦于兴趣点轨迹预测领域的关键挑战，提出融合大语言模型与轻量级纠正模型协同反思的轨迹预测方法 LLM-RFA。该方法通过轻量级纠正模型与大语言模型的协同优化机制，实现个体偏好、群体偏好等多因素信息的高效融合。实验结果表明，LLM-RFA 在 NYC、TKY、CA 数据集上的 Acc@1 准确率上超越多数现有方法，且无需针对特定数据集微调即可实现高效融合，展现出对不同密度 POI 的高适配性、高资源利用率与强泛化性能。未来可进一步融合实时交通、天气等多模态动态信息，优化长尾 POI 预测精度，推动算法在城市通勤优化、商业选址分析等场景的深度应用。

参考文献（References）：

[1] MILNER G. What is GPS? [J]. **Journal of Technology in Human Services**, 2016, 34(1): 9-12.

[2] YANG D, ZHANG D, QU B. Participatory cultural mapping based on collective behavior data in location-based social networks [J]. **ACM Transactions on Intelligent Systems and Technology (TIST)**, 2016, 7(3): 1-23.

[3] WANG J, KONG X, XIA F, et al. Urban human mobility: Data-driven modeling and prediction [J]. **ACM SIGKDD explorations newsletter**, 2019, 21(1): 1-19.

[4] LIU Q, WU S, WANG L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]//**Proceedings of the AAAI Conference on Artificial Intelligence.** Virtual Event: AAAI Press, 2016:1-8.

[5] SAK H, SENIOR A, BEAUFAYS F. Long short-term memory based recurrent neural network architectures for large vocabulary speech recognition [J]. arXiv preprint arXiv:14021128, 2014.

[6] XIE J, CHEN Z. Hierarchical transformer with spatio-temporal context aggregation for next point-of-interest recommendation [J]. **ACM Transactions on Information Systems**, 2023, 42(2): 1-30.

[7] XU S, HUANG Q, ZOU Z. Spatio-temporal transformer recommender: Next location recommendation with attention mechanism by mining the spatio-temporal relationship between visited locations [J]. **ISPRS International Journal of Geo-Information**, 2023, 12(2): 79.

[8] LI Y, CHEN T, LUO Y, et al. Discovering collaborative signals for next POI recommendation with iterative Seq2Graph augmentation. arXiv 2021 [J]. arXiv preprint arXiv:210615814.

[9] 陈满,杨小军,杨慧敏.基于图卷积网络和终点诱导的行人轨迹预测[J].**计算机应用**,2025,45(05):1480-1487.
Chen M, Yang X J, Yang H M. Pedestrian Trajectory Prediction Based on Graph Convolutional Network and Destination Induction[J]. Journal of Computer Applications, 2025, 45(05): 1480-1487.

[10] 习炎,王文格,彭景阳,等.用于行人轨迹预测的时空多图融合的稀疏图卷积网络[J/OL].**计算机工程与应用**,1-12[2025-09-27].https://doi.org/10.3778/j.issn.1002-8331.2411-0227.
Xi Y, Wang W G, Peng J Y, et al. Sparse Graph Convolutional Network with Spatiotemporal Multi-Graph Fusion for Pedestrian Trajectory Prediction[J/OL]. Computer Engineering and Applications, 1-12[2025-09-27]. https://doi.org/10.3778/j.issn.1002-8331.2411-0227

[11] JU W, QIN Y, QIAO Z, et al. Kernel-based substructure exploration for next POI recommendation[C]//**Proceedings of the 2022 IEEE International Conference on Data Mining (ICDM).** Orlando, FL: IEEE, 2022:1234-1239.

[12] LUO Y, LIU Q, LIU Z. Stan: Spatio-temporal attention network for next location recommendation[C]//**Proceedings of the Web Conference 2021.** Ljubljana: ACM, 2021:2345-2352.

[13] LIU Z, ZHANG D, ZHANG C, et al. KDRank: Knowledge-driven user-aware POI recommendation [J]. **Knowledge-Based Systems**, 2023, 278: 110884.

[14] LIM N, HOOI B, NG S K, et al. STP-UDGAT: Spatial-temporal-preference user dimensional graph attention network for next POI recommendation[C]//**Proceedings of the 29th ACM International Conference on Information & Knowledge Management.** Virtual Event: ACM, 2020:2167-2176.

[15] LI P, DE RIJKE M, XUE H, et al. Large language models for next point-of-interest recommendation[C]//**Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval.** Washington D.C.: ACM, 2024:1567-1576.

[16] TANG J, YANG Y, WEI W, et al. Graphgpt: Graph instruction tuning for large language models[C]//**Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval.** Washington D.C.: ACM, 2024: 1890-1899.

[17] RENZE M, GUVEN E. Self-reflection in large language model agents: Effects on problem-solving performance[C]//**Proceedings of the 2024 2nd International Conference on Foundation and Large Language Models (FLLM).** Dubai: IEEE, 2024:456-463.

[18] RENDLE S, FREUDENTHALER C, SCHMIDT-THIEME L. Factorizing personalized markov chains for next-basket recommendation[C]//**Proceedings of the 19th International Conference on World Wide Web.** Raleigh: ACM, 2010:811-820.

[19] FENG J, LI Y, ZHANG C, et al. Deepmove: Predicting human mobility with attentional recurrent networks[C]//**Proceedings of the 2018 World Wide Web Conference.** Lyon: ACM, 2018:1459-1468.

[20] SUN K, QIAN T, CHEN T, et al. Where to go next: Modeling long-and short-term user preferences for point-of-interest recommendation[C]//**Proceedings of the AAAI Conference on Artificial Intelligence.** New York: AAAI Press, 2020:10234-10241.

[21] YANG S, LIU J, ZHAO K. GETNext: Trajectory flow map enhanced transformer for next POI recommendation[C]//**Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval.** Madrid: ACM, 2022:1678-1687.

[22] YAN X, SONG T, JIAO Y, et al. Spatio-temporal hypergraph learning for next POI recommendation[C]//**Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval.** Taipei: ACM, 2023:1789-1798.

[23] FENG S, MENG F, CHEN L, et al. Rotan: A rotation-based temporal attention network for time-specific next poi recommendation[C]//**Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining.** Barcelona: ACM, 2024:2012-2021.

[24] GONZáLEZ L, LóPEZ A M, ÁLVAREZ J C, et al. Real-time short-term pedestrian trajectory prediction based on gait biomechanics [J]. **Sensors**, 2022, 22(15): 5828.

[25] MAZZOLI M, MOLAS A, BASSOLAS A, et al. Field theory for recurrent mobility [J]. **Nature communications**, 2019, 10(1): 3895.

[26] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//**Proceedings of the International Conference on Machine Learning.** Virtual Event: PMLR, 2021:8748-8763.

[27] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models [J]. **Advances in neural information processing systems**, 2022, 35: 24824-37.

[28] YANG D, ZHANG D, ZHENG V W, et al. Modeling user activity preference by leveraging user spatial temporal characteristics in LBSNs [J]. **IEEE Transactions on Systems, Man, and Cybernetics: Systems**, 2014, 45(1): 129-42.

[29] CHO E, MYERS S A, LESKOVEC J. Friendship and mobility: User movement in location-based social networks[C]//**Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.** San Diego: ACM, 2011:1082-1090.

[30] YANG D, FANKHAUSER B, ROSSO P, et al. Location prediction over sparse user mobility traces using rnns[C]//**Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence.** Virtual Event: IJCAI Press, 2020:3456-3462.

[31] RAO X, CHEN L, LIU Y, et al. Graph-flashback network for next location recommendation[C]//**Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining.** Washington D.C.: ACM, 2022:1987-1996.

[32] 徐成,刘宇轩,张铖,等.大语言模型驱动的言语障碍评估方法综述[J/OL].**计算机科学**,1-18[2025-09-27].https://link.cnki.net/urlid/50.1075.tp.20250618.0948.002.
Xu, C., Liu, Y. X., Zhang, C., et al. A Review of Large Language Model-Driven Methods for Speech Disorder Assessment [J/OL]. Computer Science, 1-18 [2025-09-27]. https://link.cnki.net/urlid/50.1075.tp.20250618.0948.002.